



基于Ray的蚂蚁数据构建引擎 在搜推、RAG场景的实践

谢 涛

蚂蚁AI数据构建引擎负责人

2025/12/20



谢涛

蚂蚁AI数据构建引擎负责人

个人简介：

2015年毕业于上海交通大学

先后供职于IBM、爱奇艺

2021年加入蚂蚁

深耕于分布式计算、特征计算和搜推
广索引数据处理领域

CONTENT

目录


- 01 基于Ray的海量数据构建提效
- 02 基于Ray的RAG算子体系建设
- 03 下一步展望
- 04 Q&A

基于Ray的海量数据构建提效

支撑全站万亿级正倒排，KV，KKV索引构建


问题：

1. 海量索引构建场景的资源弹性调度
2. 长尾场景的构建提效
3. 稳定性与成功率



Ray底座迁移

1. Ray C++ API
2. PBM worker Actor化
3. 集群与作业模式
4. HC, FO, 资源调度基于Ray原生能力
5. Auto Scale



Ray迁移收益


1. 容器规格从10+种减少至2种，资源弹性瓶颈消除
2. Actor轻量化改造，异构worker按需加载资源，调度overhead减少，小表构建耗时减少1倍+
3. 构建成功率和稳定性提升

基于Ray的RAG算子体系建设

算子市场：租户、计费、动态注册

算子编程范式：基于注解的算子执行与输入、输出约束

算子服务：基于Ray作业与集群模式，支撑不同场景的算子服务SLA保障



RAG算子服务- API

调用计量


按API调用次数和资源消耗进行精确计量，为计费提供数据支持，提升透明度。

权限隔离

通过租户维度的权限控制，防止越权访问，保障系统资源的安全与独立。

OAuth鉴权

基于OAuth 2.0实现多租户身份验证，确保算子调用的安全性，隔离不同租户的权限。



灵活计费

支持多种计费模式，结合计量数据实现成本分摊，满足多租户商业需求。

限流熔断

集成限流与熔断机制，防止系统过载，保障高并发下的服务稳定性。

智能路由

通过智能路由算法优化请求分发路径，提高API响应效率与系统吞吐能力。

Rag 算子开发约束

01

节点定义

通过#node注解定义算子逻辑单元，明确节点类型及其职责，形成可识别的处理节点。

02

接口契约

声明输入输出接口规范，确保数据流动的兼容性，支持模块化集成与调用。

03

初始化资源

在#setup中完成依赖加载，支持异步模型初始化，建立外部服务连接。

04

异步加载

支持延迟或按需加载大型模型，提升启动效率，避免阻塞主流程执行。

08

生命周期管理

完整覆盖从初始化到销毁的全过程，保障组件稳定与系统可靠性。

07

资源释放

#teardown负责清理内存与句柄，防止资源泄漏，确保环境干净退出。

06

幂等性要求

多次执行结果一致，避免副作用，适用于重试与容错机制场景。

05

执行逻辑

#execute实现核心处理逻辑，要求上下文隔离，保证各次执行互不干扰。



Rag 算子执行层

Code Gen模块确保算子一次编写，即可运行在多个场景

1. Ray 作业模式：支撑日常海量非结构化数据处理场景
2. Ray 集群模式：支撑响应要求较高的异步场景
3. 在线服务模式：支撑响应要求极高的在线服务场景

下一步展望

建设高性能AI数据构建引擎

1. AI Native能力集成与高性能服务保障
2. Remote shuffle service集成 支持海量结构化与非结构化数据的统一处理
3. Embedding能力



诚招英才

欢迎加入蚂蚁智能引擎技术部

一起建设下一代AI Native数据引擎



长按识别二维码
欢迎投递